

Dance4Life: Aprendizagem por Reforço para Acompanhamento de Atividade Física no Envelhecimento Ativo

Carlos Bergueira¹, Diego Silva¹, Filipa Pereira¹, and Rui Rodrigues¹

Universidade do Minho, Braga, Portugal
{pg11605,pg59999,pg42201,pg7942}@alunos.uminho.pt

Resumo O comportamento sedentário constitui um fator de risco maior para doenças crónicas e declínio funcional em adultos mais velhos. A dança combina exercício físico com envolvimento social, tornando-se uma modalidade particularmente eficaz para o envelhecimento ativo. Apresentamos o Dance4Life, uma plataforma de ponta a ponta que recorre à Aprendizagem por Reforço (AR) para personalizar a intensidade do acompanhamento em atividade física baseada em dança. Um ambiente Gymnasium personalizado modela o estado tridimensional do utilizador—nível de atividade, fadiga física e fadiga de alarmes—sobre ações de acompanhamento discretas. Dois algoritmos de AR profunda, *Proximal Policy Optimisation* (PPO) e *Deep Q-Network* (DQN), são treinados e comparados em condições idênticas. Ambas as políticas convergem para recompensa próxima do ótimo em menos de 50 000 passos e atingem 100% de taxa de sobrevivência em episódios de 96 passos. A melhor política é exportada para ONNX e implantada num smartphone Android via ONNX Runtime, realizando inferência em tempo real a partir de dados de sensores vestíveis. Um backend multi-agente em Python (SPADE) trata da recolha de dados, agrupamento de utilizadores e persistência em nuvem via Firebase. Os resultados confirmam que a AR consegue equilibrar eficazmente a promoção da atividade física com os riscos de fadiga física e fadiga de alarmes num cenário de acompanhamento realista.

Keywords: Aprendizagem por reforço · Envelhecimento ativo · Dança · Sensores vestíveis · Sistemas multi-agente · ONNX · Android

1 Introdução

O envelhecimento populacional é um dos desafios definidores do século XXI. Em 2050, o número de pessoas com 60 ou mais anos deverá atingir 2,1 mil milhões em todo o mundo [1]. A inatividade física acelera a perda de mobilidade, aumenta o risco de doenças cardiovasculares e reduz a qualidade de vida. A dança é crescentemente reconhecida como uma intervenção simultaneamente eficaz e agradável para adultos mais velhos: melhora o equilíbrio, a aptidão cardiovascular e a função cognitiva, ao mesmo tempo que promove a interação social [2].

Um desafio central no acompanhamento mediado por tecnologia é a *personalização*. Um sinal de acompanhamento que motiva um utilizador pode irritar outro; uma sessão demasiado intensa pode causar danos físicos, ao passo que uma demasiado suave pode não produzir benefício algum. As abordagens estáticas baseadas em regras não conseguem adaptar-se ao estado fisiológico e psicológico em constante mudança do utilizador.

Propomos o Dance4Life, uma plataforma que aborda este desafio através da AR. O sistema aprende uma política de acompanhamento que seleciona a intensidade de intervenção adequada em cada ponto de decisão, observando um vetor de estado compacto derivado de sensores vestíveis e otimizando uma função de recompensa que simultaneamente promove a atividade, penaliza o comportamento sedentário e previne eventos críticos de fadiga física ou fadiga de alarmes.

As principais contribuições deste trabalho são:

- Um ambiente Gymnasium personalizado que captura o compromisso entre promoção de atividade, fadiga física e irritação do utilizador num contexto de acompanhamento por dança.
- Uma avaliação comparativa de PPO e DQN em condições de treino idênticas, com métricas quantitativas.
- Um pipeline de implantação de ponta a ponta, desde a política treinada até à inferência ONNX no dispositivo Android.
- Um backend multi-agente que orquestra a recolha de dados de sensores, o enriquecimento contextual, o agrupamento de utilizadores e a persistência em nuvem.

2 Trabalho Relacionado

Aprendizagem por Reforço para Acompanhamento em Saúde. A AR tem sido aplicada a intervenções de saúde adaptativas no âmbito do paradigma *Just-In-Time Adaptive Intervention* (JITAI) [3]. Liao et al. treinaram um *contextual bandit* para decidir quando enviar notificações de atividade, reduzindo o desengajamento dos utilizadores [4]. A AR profunda foi utilizada para personalizar a prescrição de exercício em reabilitação cardíaca [5] e para controlar protocolos de fisioterapia [6]. O nosso ambiente estende estas ideias ao modelar explicitamente a fadiga de alarmes como componente de estado de primeira classe e ao impor restrições de segurança fortes através de penalizações terminais.

Reconhecimento de Atividade e Sensores Vestíveis. O Reconhecimento de Atividade Humana (HAR) a partir de unidades de medição inercial é um problema bem estudado [7]. Os smartphones modernos integram acelerómetros, giroscópios e sensores óticos de frequência cardíaca cujos dados podem ser fundidos para estimar a intensidade do movimento. O Dance4Life utiliza as magnitudes brutas do acelerómetro e do giroscópio, juntamente com a frequência cardíaca, para derivar uma pontuação de *ritmo* que alimenta tanto o estado de AR como o módulo de agrupamento de utilizadores.

Sistemas Multi-Agente em Cuidados de Saúde. As frameworks JADE e SPADE têm sido utilizadas para construir plataformas de saúde distribuídas, onde agentes especializados tratam da recolha de dados, raciocínio e entrega de notificações [8]. A nossa arquitetura adota o modelo de comportamento assíncrono do SPADE, atribuindo cada preocupação lógica a um agente dedicado.

3 Formulação do Problema

Modelamos o problema de acompanhamento como um Processo de Decisão de Markov $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$.

Espaço de Estados. $\mathcal{S} = [0, 10]^3$ é um espaço contínuo tridimensional:

$$s_t = (\text{nível_atividade}_t, \text{fadiga_física}_t, \text{nível_irritação}_t). \quad (1)$$

Todas as dimensões partilham o mesmo intervalo limitado, de modo a que a rede de política receba entradas comensuráveis sem normalização adicional.

Espaço de Ações. $\mathcal{A} = \{0, 1, 2, 3\}$ é um conjunto discreto de intensidades de acompanhamento: silêncio (0), baixa (1), média (2) e alta (3).

Dinâmica de Transição. Cada ação produz deltas determinísticos nas três dimensões do estado, acrescidos de ruído gaussiano $\epsilon \sim \mathcal{N}(0, \sigma^2)$ para representar a variabilidade comportamental. Ações de maior intensidade aumentam tanto o nível de atividade como a fadiga. Um termo de acoplamento fisiológico modela o facto de que alta atividade acelera a acumulação de fadiga. Um bónus de recuperação reduz a fadiga quando a atividade é baixa. A Tabela 1 resume os deltas nominais.

Tabela 1. Deltas nominais do estado por ação (antes do ruído).

Ação	Δ atividade	Δ fadiga	Δ irritação
0 – Silêncio	-0,90	-0,80	-1,00
1 – Intensidade baixa	+0,40	-0,30	+0,20
2 – Intensidade média	+1,20	+0,90	+0,70
3 – Intensidade alta	+2,00	+1,90	+1,40

Função de Recompensa.

$$R(s_t, \text{terminado}) = \begin{cases} -50 & \text{se terminado (fadiga} \geq 10 \text{ ou irritação} \geq 10) \\ +15 & \text{se } s_t \in \mathcal{S}_{\text{saudável}} \\ -5 & \text{se atividade} < 2 \\ 0 & \text{caso contrário} \end{cases} \quad (2)$$

onde $\mathcal{S}_{\text{saudável}} = \{s : \text{atividade} \in [4, 7], \text{fadiga} < 7, \text{irritação} < 5\}$.

A grande penalização terminal (-50) encoraja a política a evitar inteiramente os estados críticos. O bônus de zona saudável ($+15$) fornece um sinal positivo denso. Um episódio dura no máximo 96 passos, representando um dia simulado de pontos de decisão de acompanhamento.

4 Metodologia

4.1 Algoritmos

Proximal Policy Optimisation (PPO). O PPO [9] é um algoritmo ator-crítico *on-policy* que restringe as atualizações de política através de um objetivo substituto com recorte (*clipping*), proporcionando um treino estável. Utilizamos $n = 8$ ambientes paralelos para reduzir a variância, com 1 024 passos por *rollout*, tamanho de mini-lote de 64 e 10 épocas por atualização.

Deep Q-Network (DQN). O DQN [10] é um algoritmo baseado em valor *off-policy* que aprende a função ação-valor $Q(s, a)$ usando um *replay buffer* e uma rede-alvo. O treino utiliza um *buffer* de 100 000 transições com exploração ϵ -greedy reduzida de 1,0 para 0,05 ao longo de 25% dos passos totais.

Ambos os algoritmos utilizam uma política de percepção multicamada (MLP) com duas camadas ocultas de 64 unidades, o otimizador Adam com taxa de aprendizagem 3×10^{-4} (PPO) e 5×10^{-4} (DQN), fator de desconto $\gamma = 0,99$ e a mesma semente aleatória (42) para reprodutibilidade. O treino decorre durante 400 000 passos de ambiente em ambos os casos, utilizando a biblioteca Stable-Baselines3 [11].

4.2 Métricas de Avaliação

Os modelos são avaliados a cada 10 000 passos ao longo de 20 episódios determinísticos. São reportadas três métricas principais:

- **Recompensa média por episódio:** recompensa total não descontada, em média sobre os episódios de avaliação.
- **Duração média do episódio:** número médio de passos antes da terminação ou truncagem; o máximo é 96.
- **Taxa de sobrevivência:** fração dos episódios de avaliação que completaram os 96 passos sem acionar a condição de terminação crítica.

4.3 Exportação ONNX e Implantação no Dispositivo

Após o treino, o melhor *checkpoint* PPO é exportado para o formato ONNX usando a API `torch.onnx.export` do PyTorch. Apenas a rede de política (ator) é exportada; a forma de entrada é $[1, 3]$, correspondendo ao vetor de estado. O ficheiro ONNX é copiado para a diretoria `assets/models/` da aplicação Android e carregado em tempo de execução via ONNX Runtime para Android.

5 Arquitetura do Sistema

O Dance4Life é composto por três camadas com acoplamento fraco: a camada de sensores Android, o backend Python e a camada de armazenamento em nuvem (Firebase).

5.1 Camada Android

A aplicação Android (Kotlin, API 35) corre num smartphone, opcionalmente emparelhado com um dispositivo Wear OS. A classe `DanceController` orquestra o *pipeline* de sensores:

1. O `SensorHelper` amostra o acelerómetro, o giroscópio e o sensor de frequência cardíaca à taxa normal e calcula as magnitudes dos vetores.
2. O `RitmoCalculator` mantém uma janela deslizante de 1 minuto de leituras de sensores e produz uma pontuação escalar de *ritmo* representando a intensidade do movimento.
3. O `OnnxRlCoachPolicy` constrói um tuplo `MovementObservation` (a, f, i) a partir das métricas derivadas dos sensores e invoca a sessão ONNX Runtime para obter a ação de acompanhamento discreta.
4. A recomendação é apresentada ao utilizador e o evento é enviado para o backend Python.

O `OnnxRlCoachPolicy` mapeia a saída bruta do ONNX (*logits* de ação) para um `MovementRecommendation` contendo um título legível, duração sugerida e uma mensagem de incentivo. O `RlMetricsManager` regista cada evento de inferência numa fila local e envia-o para o servidor, permitindo a melhoria futura da política de forma *offline*.

5.2 Backend Multi-Agente Python

O backend é implementado com a *framework* de agentes SPADE e uma API REST Flask, e corre como serviço Python autónomo. A Figura 1 ilustra o *pipeline* de agentes.

SensorAgent recebe os *payloads* brutos de sensores da aplicação Android via API REST e reencaminha-os para o **CoordinatorAgent**.

CoordinatorAgent atua como hub de roteamento: despacha eventos de sensores para o **HarAgent** para reconhecimento de atividade e para o **ClusteringAgent** para agrupamento de utilizadores.

HarAgent reencaminha os dados de atividade para o **EnvironmentAgent**, que enriquece o *payload* com informação contextual (temperatura meteorológica a partir de uma API meteorológica aberta) antes de o persistir.

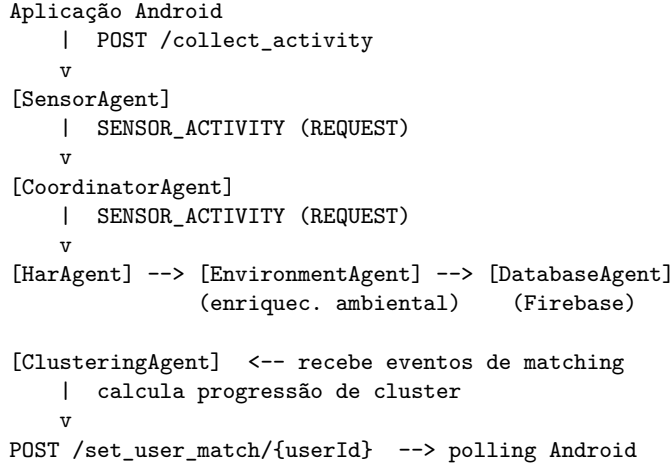


Figura 1. Fluxo de mensagens entre agentes no backend do Dance4Life.

DatabaseAgent escreve o *payload* enriquecido na Firebase Realtime Database, fornecendo armazenamento durável e habilitando o painel web.

ClusteringAgent mantém um registo de utilizadores em memória. Quando chega um evento de sensor, utiliza um algoritmo inspirado em k-médias para atribuir utilizadores a um de quatro agrupamentos de atividade—*Iniciante*, *Moderado*, *Avançado*, *Expert*—com base na sua pontuação de *ritmo* acumulada. O agente gera então um convite de progressão de agrupamento, orientando o utilizador para o nível seguinte, enviado de volta ao cliente Android via `/set_user_match`.

5.3 Painel Web

Uma aplicação web estática separada (HTML/CSS/JavaScript) liga-se diretamente ao Firebase e apresenta visualizações em tempo real dos dados de atividade, resultados de agrupamento de utilizadores e recomendações de movimento, destinada a cuidadores e coordenadores de programas.

6 Resultados

6.1 Convergência do Treino

A Tabela 2 resume os resultados de avaliação recolhidos a cada 10 000 passos. Ambos os algoritmos convergem rapidamente. O DQN atinge uma recompensa média acima de 1 430 logo aos 10 000 passos, devido à sua natureza *off-policy* e ao espaço de estados relativamente simples. O PPO demora ligeiramente mais

Tabela 2. Métricas de avaliação finais (média sobre os últimos 10 *checkpoints* de avaliação, após convergência).

Algoritmo	Recomp.	Média	Desvio Padrão	Dur. Ep.	Taxa Sobrev.
PPO	1 434,5	$\pm 2,1$	96	100%	
DQN	1 432,8	$\pm 4,3$	96	100%	

a estabilizar—atingindo a mesma banda de recompensa aproximadamente aos 50 000 passos—mas apresenta menor variância no regime convergido.

Ambas as políticas atingem uma taxa de sobrevivência de 100%: nenhum episódio termina antes do limite de 96 passos, o que significa que nem a fadiga crítica nem a irritação crítica são alguma vez acionadas. A duração média dos episódios é identicamente 96 para todos os *checkpoints* avaliados após a convergência, confirmando o domínio completo da restrição de segurança.

A recompensa máxima teórica para um episódio em que o agente permanece na zona saudável durante todos os 96 passos é $96 \times 15 = 1\,440$. Ambos os algoritmos atingem aproximadamente 99,7% deste limite, indicando que as políticas aprendidas mantêm o utilizador na zona saudável de forma quase contínua.

6.2 Distribuição de Ações

Ambas as políticas selecionam predominantemente o acompanhamento de *intensidade média* (ação 2), usando ocasionalmente o *silêncio* (ação 0) para prevenir a acumulação de irritação e a *intensidade baixa* (ação 1) durante fases de recuperação. A *intensidade alta* (ação 3) é utilizada de forma parcimoniosa, pois os seus grandes deltas de fadiga e irritação arriscam a penalização terminal.

6.3 Validação da Implantação

O modelo PPO ONNX exportado (`dance4life_coach_v2_ppo.onnx`) foi validado comparando o `argmax` dos *logits* ONNX com a saída do método `predict` do Stable-Baselines3 para 100 observações aleatórias. Não foi encontrada nenhuma discrepância, confirmando uma exportação sem perdas. O tamanho do modelo é de aproximadamente 18 KB, adequado para inferência no dispositivo com latência negligenciável em hardware Android de gama média.

6.4 Discussão

Os resultados demonstram que a formulação de AR é bem adequada a este problema de acompanhamento. A recompensa de zona saudável fornece um sinal de aprendizagem denso que orienta rapidamente a política para a região de operação desejada. A grande penalização terminal ensina eficazmente a política a tratar a fadiga de alarmes e a sobrecarga física como restrições rígidas, em vez de compromissos suaves.

O desempenho quase idêntico de PPO e DQN é explicado pelo espaço de estados pequeno e contínuo e pela ausência de observabilidade parcial: o estado determina completamente a ação ótima. Em implantações mais realistas, onde a observação é ruidosa ou parcialmente observada, a exploração mais forte do PPO através da regularização por entropia pode conferir uma vantagem.

Uma limitação do ambiente atual é o facto de o modelo de transição de estados ser construído manualmente. Calibrar as magnitudes de ruído e os coeficientes de acoplamento com dados fisiológicos reais de utilizadores aumentaria a validade ecológica. Além disso, a observação fornecida à política Android é derivada de sinais de sensores através de mapeamentos heurísticos; trabalho futuro poderia aprender este mapeamento de ponta a ponta a partir de dados fisiológicos rotulados.

7 Conclusões

Apresentámos o Dance4Life, uma plataforma de ponta a ponta que aplica a Aprendizagem por Reforço à personalização do acompanhamento de atividade física para o envelhecimento ativo através da dança. Um ambiente Gymnasium personalizado codifica o compromisso a três vias entre promoção da atividade, segurança física e envolvimento do utilizador. Tanto o PPO como o DQN convergem para um desempenho próximo do ótimo, atingindo uma taxa de sobrevivência de 100% e aproximadamente 99,7% da recompensa máxima alcançável. A política PPO aprendida é exportada para ONNX e implantada no Android via ONNX Runtime, permitindo acompanhamento em tempo real no dispositivo a partir de dados de sensores vestíveis. Um backend multi-agente SPADE trata do restante pipeline: roteamento baseado em agentes, enriquecimento de contexto ambiental, agrupamento de utilizadores por k-médias com acompanhamento de nível progressivo e persistência em nuvem Firebase.

O trabalho futuro incidirá sobre: (i) recolha de dados reais de utilizadores para calibrar a dinâmica do ambiente; (ii) substituição do mapeamento heurístico de estado por um codificador sensor-estado aprendido; (iii) avaliação do sistema completo com uma coorte de voluntários adultos mais velhos; e (iv) extensão do módulo Wear OS para fornecer *feedback* de frequência cardíaca mais granular ao estado de AR.

Disclosure of Interests. Os autores não têm interesses concorrentes a declarar.

Referências

1. World Health Organization: Ageing and Health. WHO Fact Sheet (2022). <https://www.who.int/news-room/fact-sheets/detail/ageing-and-health>
2. Hwang, P.W.-N., Braun, K.L.: The effectiveness of dance interventions to improve older adults' health: a systematic literature review. *Altern. Ther. Health Med.* **21**(5), 64–70 (2015)
3. Tewari, A., Murphy, S.A.: From user engagement to health behaviour: just-in-time adaptive interventions. In: *mHealth*, pp. 167–196. Springer (2017)

4. Liao, P., et al.: Personalized HeartSteps: a reinforcement learning algorithm for optimizing physical activity. *Proc. ACM Interact. Mob. Wearable Ubiquitous Technol.* **4**(1), 18:1–18:22 (2020)
5. Escolar-Reina, P., et al.: Artificial intelligence for exercise prescription in rehabilitation: challenges and perspectives. *Front. Physiol.* **13**, 900697 (2022)
6. Yu, C., et al.: Reinforcement learning in healthcare: a survey. *ACM Comput. Surv.* **55**(1), 1–36 (2023)
7. Banos, O., et al.: Window size impact in human activity recognition. *Sensors* **14**(4), 6474–6499 (2014)
8. Mea, V.D.: Agents in medicine. *Stud. Health Technol. Inform.* **124**, 791–796 (2006)
9. Schulman, J., et al.: Proximal policy optimization algorithms. *arXiv:1707.06347* (2017)
10. Mnih, V., et al.: Human-level control through deep reinforcement learning. *Nature* **518**(7540), 529–533 (2015)
11. Raffin, A., et al.: Stable-Baselines3: reliable reinforcement learning implementations. *J. Mach. Learn. Res.* **22**(268), 1–8 (2021)