

# Dance4Life: Plataforma de Sensorização para Envelhecimento Ativo através da Dança

Carlos da Mota Bergueira (pg11605@alunos.uminho.pt)  
Diego Jefferson Mendes Silva (pg59999@alunos.uminho.pt)  
Filipa Araújo Pereira (pg42201@alunos.uminho.pt)  
Rui Manuel Martins Marques Rodrigues (pg7942@alunos.uminho.pt)

Universidade do Minho, Braga, Portugal

**Abstract.** Este artigo apresenta o Dance4Life, uma plataforma de sensorização e inteligência artificial desenvolvida no âmbito da unidade curricular de Sensorização e Ambiente do Mestrado em Inteligência Artificial. O sistema tem como objetivo promover o envelhecimento ativo através da dança, integrando dados meteorológicos (OpenWeatherMap) com dados fisiológicos, inerciais e de localização recolhidos em dispositivos Android (smartphone e wearables). A arquitetura assenta em três pilares: um servidor Flask para ingestão e encaminhamento de dados, uma camada de agentes para processamento e persistência, e uma camada de visualização interativa com PowerBI e D3.js/Leaflet para análise exploratória. Em paralelo, os dados suportam o desenvolvimento de um agente de Aprendizagem por Reforço (RL), treinado em ambiente simulado estocástico (**MovementEnv**) com algoritmos DQN e PPO, para otimização de intervenções personalizadas. O trabalho demonstra a viabilidade de uma plataforma distribuída, centrada no utilizador sénior, que combina contexto ambiental, segurança fisiológica e motivação social através da música e da dança.

**Keywords:** Sensorização · Dance4Life · Envelhecimento Ativo · Machine Learning · HAR

## 1 Introdução

O envelhecimento da população europeia constitui um dos maiores desafios sociais e de saúde pública do século XXI. Em Portugal, estima-se que, em 2050, mais de 35% da população terá mais de 65 anos. O Dance4Life surge como resposta a este desafio, propondo uma plataforma inteligente que combina sensorização ambiental e fisiológica com mecanismos de ludificação baseados na dança e na música. O sistema é concebido para funcionar em dispositivos móveis (smartphones e smartwatches), processando dados localmente segundo o paradigma de Edge Computing, em conformidade com os princípios de Privacy by Design exigidos pelo RGPD. Este relatório documenta a segunda fase do trabalho prático, focada na implementação da plataforma: a definição e implementação dos coletores de dados, o tratamento e visualização dos dados recolhidos, e a conceção do agente de Aprendizagem por Reforço.

(RL) desenvolvido no contexto da unidade curricular de Aprendizagem por Reforço. Complementarmente, apresenta-se uma proposta de modelo de negócio que enquadra a viabilidade da solução em contextos reais. O documento está organizado da seguinte forma: a Secção 2 descreve a arquitetura global do sistema e os domínios abordados; a Secção 3 detalha os sensores e os coletores de dados implementados; a Secção 4 apresenta a exploração e visualização dos dados; a Secção 5 descreve o agente de Aprendizagem por Reforço concebido; a Secção 6 analisa resultados e limitações; e a Secção 7 apresenta o modelo de negócio.

## 2 Domínios, Objetivos e Arquitetura

### 2.1 Domínios Abordados

O Dance4Life opera na intersecção de três domínios principais:

**Saúde e Bem-Estar Sénior** Monitorização da atividade física, frequência cardíaca e padrões de movimento, com o objetivo de promover o exercício seguro e personaliza-do.

**Ambiente Urbano Inteligente** Integração de dados contextuais do ambiente, com foco nas condições meteorológicas e de localização, para adaptar as recomendações de atividade ao contexto real do utilizador.

**Interação Social e Ludificação** Matching de utilizadores com perfis compatíveis (Dancing Match) e estímulos musicais adaptativos que transformam a monitorização passiva numa experiência ativa e motivadora.

### 2.2 Objetivos

Os objetivos da fase prática organizam-se em três níveis: Implementar coletores de dados para sensores físicos e virtuais, integrando a API OpenWeatherMap e a recolha de dados em dispositivos Android (smartphone e wearables). Explorar, tratar e visualizar os dados recolhidos, aplicando técnicas de visualização interativa com D3.js para análise de padrões temporais e correlações entre variáveis ambientais e fisiológicas. Conceber e implementar um agente de Aprendizagem por Reforço (RL) para otimização da política de intervenção do sistema Dance4Life, equilibrando a promoção da atividade física com a prevenção de fadiga de alarme.

### 2.3 Arquitetura Global do Sistema

A arquitetura do Dance4Life segue um modelo distribuído em camadas, conforme ilustrado na Figura 1. A camada de aquisição de dados agrega três tipos

de fontes: dados meteorológicos (OpenWeatherMap), dados de sensores inerciais/fisiológicos dos dispositivos Android e dados de localização. Os dados convergem num servidor Flask central, responsável pela receção, validação, encaminhamento para agentes e persistência em base de dados. Uma camada de processamento alimenta o agente de Aprendizagem por Reforço responsável pelas decisões de intervenção. Por fim, uma camada de apresentação expõe dashboards interativos com PowerBI, D3.js e Leaflet para análise exploratória dos dados.

A separação entre a camada de Edge (dispositivos móveis) e a camada de servidor garante que os dados biométricos granulares são processados localmente, transmitindo apenas inferências categóricas anonimizadas para o servidor central, em conformidade com o RGPD.

### 3 Sensores, Coletores de Dados e Ambiente

#### 3.1 Sensores Virtuais Ambientais

Na implementação atual, o contexto ambiental é obtido através de um módulo de sensorização virtual meteorológica. Este sensor permite ao sistema adaptar recomendações de atividade em função das condições climáticas no momento da recolha.

**Sensor Meteorológico (OpenWeatherMap)** O módulo `external_sensors.py` recolhe dados meteorológicos em tempo real, recorrendo à API REST da OpenWeatherMap (endpoint `/data/2.5/weather`). A consulta pode ser realizada por coordenadas geográficas (latitude/longitude) ou por cidade. Os parâmetros recolhidos incluem temperatura (°C), humidade relativa (%), velocidade do vento (m/s) e timestamp Unix da observação. Os dados são obtidos em unidades métricas (`units=metric`) e retornados como dicionário Python, facilitando a integração com os restantes módulos. A relevância deste sensor para o Dance4Life reside na capacidade de contextualizar a atividade física: temperaturas extremas ou humidade elevada condicionam a intensidade recomendada pelo sistema, enquanto condições favoráveis podem ser utilizadas como estímulo adicional para atividade ao ar livre.

**Simulador Dispositivo Android** O módulo `_simulate_android_emulator.py` replica o comportamento de um dispositivo Android equipado com sensores inerciais e fisiológicos, enviando dados simulados para o servidor Flask através de pedidos HTTP POST. Cada payload gerado inclui um identificador de utilizador (`user_1` a `user_5`), leituras de acelerómetro (`acc`, normalizado entre 0 e 1), frequência cardíaca (`hr`, entre 60 e 160 bpm), ritmo de movimento (`ritmo`, entre 0 e 1), coordenadas GPS (`latitude` e `longitude`, na região do Porto) e timestamp UTC. A geração de dados segue uma distribuição aleatória uniforme, o que permite testar o comportamento do sistema em condições diversas de atividade. Os dados são enviados com um intervalo de 30 segundos, simulando a cadência de amostragem de um dispositivo real em contexto de monitorização


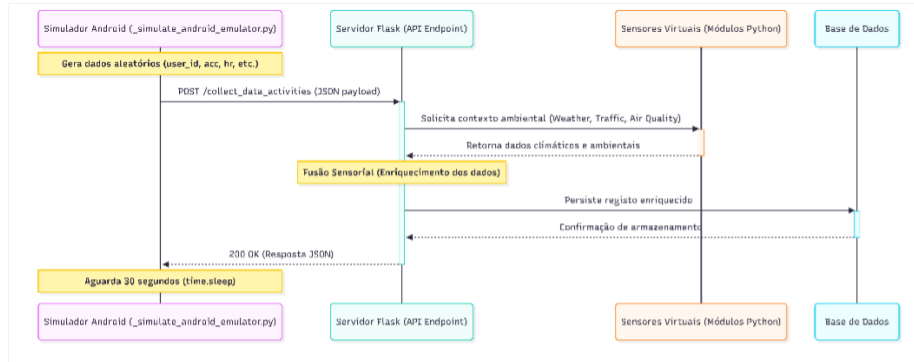


Fig. 1. Arquitetura global do sistema Dance4Life.

contínua. O mecanismo de timeout configurado (3 segundos de ligação, 20 segundos de leitura) garante robustez perante latências do servidor. O endpoint de receção (`/collect_data_activities`) foi configurado no servidor Flask local (`localhost:5000`), com suporte para endereçamento alternativo em rede local, facilitando testes em cenários de dispositivos fisicamente distribuídos.

### 3.2 Servidor de Recolha de Dados (Flask)

O servidor Flask constitui o núcleo da camada de recolha de dados, expondo endpoints REST para receção dos dados provenientes do simulador Android e para consulta dos dados ambientais recolhidos pelos sensores virtuais. A arquitetura do servidor segue o padrão MVC simplificado, com separação entre a lógica de receção de dados, a camada de persistência em base de dados e os módulos de sensorização. A cada pedido recebido no endpoint `/collect_data_activities`, o servidor valida o payload JSON, adiciona metadados temporais e encaminha os dados para os agentes de processamento (HAR, ambiente, base de dados, coordenador e matching). O enriquecimento ambiental, aplicado em tempo de execução, centra-se na variável de temperatura. Esta fusão de dados sensoriais e contextuais numa operação de ingestão integrada constitui um dos elementos distintivos da arquitetura Dance4Life.



**Fig. 2.** Diagrama de sequência do fluxo de recolha de dados.

## 4 Exploração e Visualização dos Dados

### 4.1 Tratamento e Pré-Processamento

Na implementação atual, o tratamento de dados ocorre em duas fases complementares:


**Validação e enriquecimento em ingestão** no servidor Flask, cada payload recebido é validado a nível estrutural (JSON válido e campos esperados), enriquecido com metadados temporais e encaminhado para os agentes de processamento.

**Agregação para análise** no dashboard PowerBI/D3.js, os dados persistidos são agregados por utilizador, mês, cidade e estado de convite, permitindo análise exploratória comparativa e cálculo de indicadores de participação (atividade, convites aceites, matching e recomendações).

## 4.2 Análise Exploratória

A análise exploratória dos dados recolhidos focou-se na identificação de padrões temporais e comportamentais de utilização da plataforma. A distribuição de atividade por utilizador permitiu distinguir perfis de maior e menor participação, enquanto a análise temporal mensal evidenciou variações no volume de recolha ao longo do período observado. A análise por cidade, suportada por visualização georreferenciada, permitiu identificar concentração de atividade em determinados contextos geográficos. Adicionalmente, a distribuição de estados de convite (aceite, recusado, pendente) e os indicadores de matching forneceram uma perspetiva complementar sobre o envolvimento social promovido pelo sistema.

### Visualização Dance4Life




**Fig. 3.** Séries temporais das variáveis sensoriais recolhidas (D3.js).

### 4.3 Técnicas de Visualização Implementadas

As visualizações foram implementadas recorrendo à biblioteca D3.js, escolhida pela sua flexibilidade e capacidade de renderização interativa de grandes volumes de dados temporais. Foram desenvolvidos os seguintes tipos de visualização:

- Gráfico de barras (Top 10): comparação dos utilizadores com melhor score global, agregando atividade, convites aceites, matching e recomendações.
- Série temporal mensal (line chart): evolução do número de registos de atividade ao longo do tempo.
- Mapa por cidade (Leaflet + D3): distribuição geográfica da atividade, com codificação visual por intensidade de registos.
- Distribuição de convites por estado: visualização comparativa entre convites aceites, recusados e pendentes.
- Cartão individual de utilizador com gráfico circular: decomposição do score por componentes de participação.



**Fig. 4.** Visualização de intensidade de atividade no dashboard (D3.js).

## 5 Modelos de Machine Learning

O motor de decisão inteligente do Dance4Life é implementado através de um agente de Aprendizagem por Reforço (RL), desenvolvido no âmbito da unidade

curricular de Aprendizagem por Reforço do Mestrado em Inteligência Artificial. O agente é responsável por aprender uma política ótima de intervenção, decidindo em cada momento quando e com que intensidade intervir junto do utilizador sénior, equilibrando dois objetivos críticos em geriatria: a promoção da atividade física (combate ao sedentarismo) e a preservação do bem-estar psicológico (prevenção de fadiga de alarme e rejeição tecnológica).

### 5.1 Problema de Classificação e Classes

O problema é formalmente modelado como um Processo de Decisão de Markov (MDP), estruturado da seguinte forma:

**Espaço de Estado** O espaço de observação é contínuo, composto por três variáveis dinâmicas com valores no intervalo  $[0, 10]$ , que representam o estado multidimensional do utilizador em cada instante temporal:

**Table 1.** Espaço de estado do MDP do agente Dance4Life.

| Variável de Estado           | Intervalo | Descrição                                                         |
|------------------------------|-----------|-------------------------------------------------------------------|
| Nível de Atividade           | $[0, 10]$ | Grau atual de movimento do utilizador (0 = sedentarismo absoluto) |
| Fadiga Física                | $[0, 10]$ | Cansaço fisiológico/cardíaco acumulado ao longo da sessão         |
| Irritação (Fadiga de Alarme) | $[0, 10]$ | Saturação psicológica pelas notificações enviadas pelo sistema    |

**Espaço de Ação** O espaço de ação é discreto, com quatro níveis de intensidade de intervenção que o agente pode selecionar em cada timestep:

- Ação 0 Silêncio: Nenhuma intervenção. Prioriza o descanso e reduz a irritação, mas conduz à queda progressiva do nível de atividade.
- Ação 1 Baixa Intensidade: Incentivo leve (ex.: notificação suave ou sugestão musical subtil). Mantém o nível de atividade base e apoia a recuperação, com ligeiro incremento da irritação.
- Ação 2 Média Intensidade: Recomendação moderada (ex.: sugestão de sessão de dança leve). Aumenta a atividade para níveis saudáveis, com incremento equilibrado de fadiga e irritação.
- Ação 3 Alta Intensidade: Desafio forte (ex.: convite a sessão de dança ativa com parceiro). Maximiza a atividade em casos críticos de sedentarismo, mas com custo elevado em fadiga e irritação.



**Table 2.** Função de recompensa do agente de Aprendizagem por Reforço.

| Recompensa     | Condição e Descrição                                                                        |
|----------------|---------------------------------------------------------------------------------------------|
| +15 (contínua) | Utilizador na zona ideal: Atividade $[4, 7]$ , Fadiga $< 7$ e Irritação $< 5$               |
| -5 (contínua)  | Utilizador em sedentarismo perigoso: Atividade $< 2$ por timestep                           |
| -50 (terminal) | Estado de Game Over: Fadiga Máxima (risco médico) OU Irritação Máxima (abandono do sistema) |

**Função de Recompensa** A função de recompensa foi cuidadosamente desenhada para codificar os objetivos clínicos e comportamentais do sistema, penalizando estados de risco e recompensando a manutenção do utilizador na zona de atividade ideal:

A penalização terminal de -50 é particularmente relevante: modela dois cenários de falha crítica distintos – o risco médico por exaustão fisiológica e o abandono técnico por fadiga de alarme – ambos determinando o fim do episódio. Esta dualidade obriga o agente a aprender uma política equilibrada que não apenas maximize a atividade, mas também gerencie ativamente a saturação psicológica do utilizador.


## 5.2 Ambiente Simulado MovementEnv

Devido às restrições éticas que impedem o treino inicial com utilizadores reais (população sénior vulnerável), o agente é treinado num ambiente simulado estocástico designado **MovementEnv**, desenvolvido com a framework Gymnasium da Farama Foundation. Este ambiente imita a evolução fisiológica e comportamental de um utilizador idoso, gerando estados dinâmicos e reagindo às intervenções do agente de forma realista. O ambiente incorpora estocasticidade nas transições de estado, modelando a variabilidade natural do comportamento humano: a mesma ação do agente pode produzir respostas ligeiramente diferentes em diferentes episódios, replicando a imprevisibilidade inerente a utilizadores reais. A integração com o ecossistema Dance4Life permite que os dados ambientais recolhidos pelos sensores virtuais (temperatura, qualidade do ar) influenciem os parâmetros de transição do ambiente simulado, enriquecendo o realismo da simulação.

## 5.3 Algoritmos Implementados: DQN e PPO

Foram implementados e avaliados comparativamente dois algoritmos de Deep Reinforcement Learning, selecionados pela sua adequação às características do problema (estados contínuos, ações discretas), recorrendo à biblioteca Stable-Baselines3.

**DQN Deep Q-Network** O DQN é um algoritmo baseado em valor (value-based) que aproxima a função  $Q(s, a)$  – o valor esperado de executar a ação  $a$  no



**Fig. 5.** Ciclo de interação do agente RL com o ambiente `MovementEnv`.

estado  $s$  através de uma rede neuronal profunda. Utiliza dois mecanismos fundamentais para estabilizar o treino em ambientes com estados contínuos: Experience Replay (armazenamento e amostragem aleatória de experiências passadas para quebrar correlações temporais) e Target Network (rede alvo de atualização lenta para evitar oscilações na função de valor). A sua natureza value-based torna-o particularmente adequado para espaços de ação discretos como o definido no MDP `Dance4Life`.

**PPO Proximal Policy Optimization** O PPO é um algoritmo baseado em política (policy-based/actor-critic), reconhecido no estado da arte pela sua estabilidade de treino e facilidade de convergência. O mecanismo central do PPO é a função objetivo clipped surrogate, que limita a magnitude das atualizações de política a cada iteração, evitando passos de gradiente demasiado grandes que poderiam desestabilizar o agente. A componente critic estima o valor do estado atual, guiando as atualizações da componente actor (a política propriamente dita). A robustez do PPO em ambientes estocásticos torna-o o candidato preferencial para o cenário `Dance4Life`.

#### 5.4 Métricas de Avaliação e Comparação

A avaliação e comparação dos dois agentes (DQN vs. PPO) é realizada através das seguintes métricas:

**Curvas de Aprendizagem** evolução da recompensa média por episódio ao longo dos timesteps de treino, permitindo avaliar a velocidade de convergência e a estabilidade de cada algoritmo.

**Duração Média dos Episódios** capacidade do agente para manter o utilizador ativo ao longo de uma sessão completa sem desencadear um estado terminal (Game Over por fadiga ou abandono).

**Survival Rate** proporção de episódios concluídos com sucesso total, sem atingir nenhum dos limites críticos definidos na função de recompensa.

**Análise Comparativa de Política** exame das políticas aprendidas por cada agente quais ações são preferidas em que estados para avaliar a adequação clínica das decisões tomadas.

**Table 3.** Comparação de desempenho DQN vs. PPO no ambiente **MovementEnv**.

| Métrica                                   | DQN     | PPO     |
|-------------------------------------------|---------|---------|
| Recompensa Média (30 episódios)           | 1437.50 | 1436.00 |
| Duração Média de Episódio (passos)        | 96.00   | 96.00   |
| Survival Rate                             | 100.00% | 100.00% |
| Timesteps até melhor desempenho observado | 20 000  | 260 000 |

## 6 Resultados, Limitações e Recomendações

### 6.1 Sumário dos Resultados Obtidos

A implementação da plataforma Dance4Life na sua fase prática permitiu alcançar os seguintes resultados:

- Integração do sensor virtual meteorológico (OpenWeatherMap), com recolha contínua de dados ambientais para suporte contextual.
- Implementação de um simulador de dispositivo Android funcional, capaz de gerar e transmitir dados fisiológicos e inerciais realistas para o servidor Flask com intervalo de 30 segundos.
- Desenvolvimento de um servidor Flask robusto, com mecanismo de fusão sensorial na ingestão e persistência em base de dados relacional.
- Criação de um conjunto de visualizações PowerBI e D3.js/Leaflet interativas que permitem a análise exploratória dos dados recolhidos, incluindo ranking, série temporal, distribuição geográfica e estado de convites.
- Conceção e avaliação comparativa de dois agentes de Aprendizagem por Reforço (DQN e PPO) num ambiente simulado estocástico (**MovementEnv**), com formulação MDP documentada e métricas de avaliação definidas.

## 6.2 Análise Crítica e Limitações

A principal limitação da implementação atual reside na utilização exclusiva de dados simulados tanto para os sensores inerciais e fisiológicos como para o ambiente de treino do agente RL (**MovementEnv**). Os dados gerados seguem distribuições estocásticas parametrizadas que, embora mais realistas do que distribuições uniformes simples, não capturam a plena complexidade e variabilidade real dos padrões fisiológicos e comportamentais de utilizadores seniores. Esta limitação condiciona a capacidade de generalização da política aprendida pelo agente para contextos do mundo real. Uma limitação adicional reside na cobertura ambiental ainda centrada em variáveis meteorológicas, o que reduz a representatividade de contexto face a cenários urbanos mais complexos. Do ponto de vista do agente RL, a estocasticidade do ambiente **MovementEnv** introduz variância nas estimativas de recompensa durante o treino. Na avaliação comparativa realizada (30 episódios), ambos os modelos apresentaram survival rate de 100% e duração média de 96 passos por episódio; o DQN obteve recompensa média ligeiramente superior, enquanto o PPO mostrou comportamento igualmente estável. Estes resultados sugerem desempenho robusto dos dois métodos no ambiente simulado, carecendo ainda de validação com dados reais.

## 6.3 Recomendações para Trabalho Futuro

Com base na análise crítica realizada, identificam-se as seguintes recomendações para o desenvolvimento futuro da plataforma:

- Validação do agente RL com utilizadores reais ou com dados recolhidos de voluntários, substituindo gradualmente o **MovementEnv** por um ambiente de simulação calibrado com dados empíricos reais de população sénior.
- Extensão do espaço de estado do MDP com variáveis contextuais adicionais, permitindo ao agente adaptar as intervenções ao contexto ambiental em tempo real de forma mais robusta.
- Implementação do paradigma de Federated Learning para personalização distribuída da política do agente, preservando a privacidade e adaptando as intervenções às características biomecânicas individuais de cada utilizador.
- Integração de um módulo de inferência implícita de preferências musicais, correlacionando os dados de acelerómetro com as músicas reproduzidas, para enriquecer o espaço de ação do agente com recomendações musicais personalizadas.
- Desenvolvimento de uma interface móvel nativa (Android/iOS) para substituição gradual do simulador e testes em condições reais de utilização.

# 7 Modelo de Negócio

## 7.1 Proposta de Valor e Cliente-Alvo

O Dance4Life posiciona-se como uma plataforma B2B2C (Business-to-Business-to-Consumer), cujo cliente primário são instituições de cuidado sénior centros

de dia, lares de idosos e programas municipais de envelhecimento ativo e cujo utilizador final é a população sénior (65+ anos). A proposta de valor diferencia-se em três eixos: personalização baseada em dados (adaptação da atividade e da música ao perfil individual), segurança fisiológica (monitorização da frequência cardíaca e alertas em tempo real), e combate ao isolamento social (emparelhamento social - Dancing Match).

## 7.2 Parcerias Estratégicas

A viabilidade do Dance4Life assenta num ecossistema de parcerias estratégicas:

- Instituições de saúde e cuidado sénior: parceiros de distribuição e validação clínica (ex.: Santa Casa da Misericórdia, SCML, Misericórdias locais).
- Fabricantes de wearables: integração nativa com dispositivos como Fitbit, Garmin ou Apple Watch para acesso a dados fisiológicos reais de alta qualidade.
- Serviços de streaming musical: licenciamento de conteúdo musical adaptado (ex.: Spotify API, TIDAL) para alimentar o motor de recomendação musical.
- Municípios e programas de saúde pública: parceiros de financiamento no contexto de cidades inteligentes e políticas de envelhecimento ativo.

## 7.3 Estratégia de Monetização

A estratégia de monetização combina dois modelos complementares:

- Subscrição institucional (SaaS): licença mensal por instituição, com preço escalável em função do número de utilizadores ativos. Este modelo garante receita recorrente e previsível.
- Modelo freemium para utilizadores individuais: versão gratuita com funcionalidades básicas (monitorização de atividade e sugestões musicais), e versão premium com funcionalidades avançadas (em-parelhamento social, relatórios de saúde detalhados, integração com wearables).

Adicionalmente, os dados anonimizados e agregados gerados pela plataforma constituem um ativo de valor para investigação académica e para entidades de saúde pública, abrindo uma terceira linha de receita através de parcerias de investigação e venda de insights analíticos, sempre em conformidade com o RGPD.

## 8 Conclusão

O presente trabalho documentou o desenvolvimento da fase prática do projeto Dance4Life, uma plataforma de sensorização e inteligência artificial para a promoção do envelhecimento ativo através da dança. A implementação demonstrou a viabilidade técnica da integração de dados meteorológicos (OpenWeatherMap) com dados de dispositivos Android (smartphone e wearables), num servidor Flask capaz de realizar ingestão, encaminhamento por agentes e persistência em

tempo real. A exploração dos dados recolhidos através de visualizações PowerBI e D3.js/Leaflet revelou padrões temporais, geográficos e de participação social úteis para monitorização do sistema. O agente de Aprendizagem por Reforço concebido com formulação MDP e implementação comparativa de DQN e PPO constitui o motor de decisão inteligente da plataforma, capaz de aprender políticas de intervenção que equilibram atividade física e bem-estar psicológico. O Dance4Life demonstra como a convergência de sensorização ambiental, processamento inteligente e ludificação pode criar uma solução tecnológica diferenciada para um dos maiores desafios sociais contemporâneos: o envelhecimento ativo. A proposta de modelo de negócio delineada reforça a viabilidade da solução em contextos reais, abrindo caminho para uma implementação piloto em parceria com instituições de cuidado sénior. Como trabalho futuro, a prioridade recai na substituição dos dados simulados por dados reais de utilizadores seniores e na implementação do módulo de Aprendizagem Federada, que permitirá ao sistema aprender de forma distribuída e privacidade-preservante, completando a visão de um sistema verdadeiramente inteligente, adaptativo e centrado no utilizador.

## References

1. Bouchabou, D., Nguyen, S.M., Lohr, C., LeDuc, B., Kanellos, I.: A Survey of Human Activity Recognition in Smart Homes Based on IoT Sensors Algorithms. *Sensors* 21(18), 6037 (2021).
2. Liu, C., Thiamwong, L., Nguyen, T., Suarez, J.R., Park, J.-H., Lou, Q., Xie, R.: A reinforcement learning approach to enhance physical activity and reduce fall risk in older adults. *Innovation in Aging* 8(Suppl. 1), 1081–1081 (2024). <https://doi.org/10.1093/geroni/igae098.3473>
3. Gönül, S., Naml, T., Coar, A., Toroslu, I.H.: A reinforcement learning based algorithm for personalization of digital, just-in-time, adaptive interventions. *Artificial Intelligence in Medicine* 115, 102062 (2021). <https://doi.org/10.1016/j.artmed.2021.102062>
4. Hossen, M.A., Abas, P.E.: Machine Learning for Human Activity Recognition: State-of-the-Art Techniques and Emerging Trends. *J. Imaging* 11(3), 91 (2025).
5. Liao, P. et al.: Personalized HeartSteps: A Reinforcement Learning Algorithm for Optimizing Physical Activity. *ACM* (2019). <https://doi.org/10.1145/3381007>
6. Lu, Y. et al.: StepCountJITAI: simulation environment for RL with application to physical activity adaptive intervention. *arXiv:2411.00336* (2024).
7. Paraschiakos, S. et al.: Activity recognition using wearable sensors for tracking the elderly. *User Model. User-Adapt. Interact.* 30, 567-605 (2020).
8. Peng, C. et al.: Promoting physical activity in middle-aged and older adults through digital intervention via deep reinforcement learning. *Int. J. Human-Computer Interaction* (2024). <https://doi.org/10.1080/23311908.2025.2541720>
9. Gymnasium (Farama Foundation): Framework para ambientes de Aprendizagem por Reforço. <https://gymnasium.farama.org/> (acedido em maio de 2026).
10. Stable-Baselines3: Biblioteca de algoritmos de Deep RL em PyTorch. <https://stable-baselines3.readthedocs.io/> (acedido em maio de 2026).
11. OpenWeatherMap API Documentation. <https://openweathermap.org/api> (acedido em maio de 2026).